Компилятор признаков для RecSys

Решение задания про автоматизацию инженерии признаков в рекомендательных системах.

> **Тезис.** «Ручные фичи против выученных представлений» — ложная дихотомия. Ручная фича не эвристика, а **плохо параметризованная программа в маленьком типизированном пространстве**. Её не надо заменять трансформером. Её надо **скомпилировать**.

Содержание

1. Что сделано
2. Главные результаты
3. Грамматика признаков
4. Эксперимент 1: окна против затуханий
5. Моменты возрастов: правильный примитив
6. Эксперимент 2: существует ли «правильное окно»
7. Протокол оценки
8. Эксперимент 3: сквозной бенчмарк
9. Эксперимент 4: идея про ИИ-агента
10. Эксперимент 5: аудит утечки
11. Эксперимент 6: масштабирование
12. Эксперимент 7: отбор под бюджет
13. Чего метод НЕ делает
14. Воспроизведение

Что сделано

Ручная RecSys-фича раскладывается на три составляющие:

```
фича = СТАТИСТИКА над событиями типа E
       на КЛЮЧЕ K        (user / item / user×item / user×category / ...)
       с ВРЕМЕННЫМ ЯДРОМ (окно 7 дней)
       до момента t
```

Человек выбирает `K`, `E` и ядро — и больше ничего. Все три выбора перечислимы. Значит «придумывание фичей» заменяется **компилятором**: на входе схема данных и лог, на выходе — тысячи признаков, посчитанных за один проход, без утечки по построению, с отбором под бюджет памяти.

Человек не выбирает ни ключи, ни окна, ни агрегаты.

Как это соотносится с тремя идеями из задания

Идея из задания	Что показано здесь
1. ИИ-агент пишет SQL	Неверный уровень абстракции. Пространство настолько структурировано, что его надо **перечислять**, а не угадывать. Замерено: 19 из 27 признаков, предлагаемых языковой моделью, уже порождаются грамматикой автоматически. Ценность агента — в остатке, и он выписан по пунктам (эксп. 4).
2. Графы, link prediction	Субсумируется. «Косвенные признаки» из задания (user→item_category) — это мета-путь длины 2 в гетерогенном графе. Перечисление ключей и есть перечисление мета-путей, но ценой O(1) на событие вместо обучения эмбеддингов.
3. Трансформер на весь лог	Претензия задания к масштабируемости проверена измерением, и ожидание не подтвердилось: состояние компилятора растёт как **N^0.47**, а не выходит на плато. Настоящее структурное преимущество на другой оси — память **не зависит от горизонта признака**: при росте горизонта в 365× она меняется в 1.00×, тогда как жёстким окнам нужно в 5.56× больше (эксп. 6).

Главные результаты

Итог одной строкой

На реальных данных (RetailRocket) **компилятор значимо обыгрывает затюненный ручной бустинг при нулевом участии человека**: NDCG@10 **0.4117** против **0.3733**, доверительные интервалы не пересекаются, прирост **+10.3%** относительно.

Но прочитать этот результат можно только вместе со следующим разделом. Разница стала видна **лишь после того, как был исправлен протокол измерения** — на стандартном протоколе все методы упирались в один потолок и были неразличимы.

Почему протокол пришлось переделать

Три замера на реальных данных, каждый воспроизводится командой `make e08`.

1. Предсказание покупки без разрыва — это не рекомендация. У 97.6% покупок было предыдущее касание того же айтема, **медианный разрыв 4 минуты**, 90.6% покупок внутри часа. То есть «предсказание покупки» означает «юзер минуту назад открыл карточку товара» — детекция намерения внутри сессии. Система, срабатывающая после того, как человек сам нашёл товар, рекомендовать не умеет. Введён разрыв предсказания в сутки: тривиальный признак «видел ли айтем» падает с AUC 0.8777 до **0.4952**, то есть до случайного.

2. Негативы по популярности вырождают задачу. Один бинарный признак «видел ли юзер этот айтем» даёт **NDCG@10 = 0.8780**, потому что лишь 1.3% негативов вообще встречались пользователю. Любое число рядом с этим на таком протоколе не говорит о модели ничего. Негативы собираются как у ретривера: история 40%, та же категория 30%, популярность 30%.

3. Джойн атрибутов «последнее известное значение» — тихая утечка. Свойства айтема в RetailRocket временные. Корректный as-of джойн знает категорию в **79.7%** событий, наивный — в **96.6%**: 16.9 пункта чистой информации из будущего. Эта утечка **не ловится** проверкой агрегатов, потому что сидит в джойне. В первой версии `build_queries` она была и у нас — нашлась, исправлена, покрыта тестом.

Пять результатов против собственных гипотез

Они оставлены как есть, потому что именно они определили конструкцию.

1. Базис затуханий НЕ заменяет жёсткие окна. Исходная гипотеза: окно приближается смесью экспонент, значит сетка затуханий покрывает все окна сразу. Неверно. Индикатор окна разрывен в `s=W`; sup-ошибка **0.52 не убывает** при росте числа экспонент с 2 до 32, норма коэффициентов растёт до **$3.6 \cdot 10^5$**, а на уровне признака **$R^2 \approx -10^8$**. Восстановление окна из базиса затуханий — плохо обусловленная обратная задача Лапласа. *Следствие:* теоретически вопрос «что лучше» не решается, только экспериментом. Отсюда вся дальнейшая конструкция.

2. AUC не годится для отбора временных окон. Признаки с полупериодами **0.6 дня и 12 дней дают одинаковый AUC до четвёртого знака** (0.7424), хотя содержат разное количество информации (57% нулей против 38%). AUC ранговый и насыщается. Идентифицирует масштаб log-loss: на полигоне с известным оптимумом он находит истину в пределах разрешения сетки (1.07× / 0.99× / 1.10×), AUC промахивается в 8 раз.

3. «Правильный полупериод» не выводится из знания механизмов. На полигоне, где все константы заданы нами: `τ_cat` менялся в 36× — оптимум сдвинулся в 3.6× и насытился; на `τ_item` реакция **немонотонная**; сдвиг одного параметра смещает оптимум **чужих** семейств ключей в 1.5–3.6×, потому что механизмы связаны. Если масштаб не выводится из полного знания устройства полигона, на реальных данных его не выведет ни интуиция, ни доменный эксперт. Остаётся измерять — то есть держать всю сетку.

4. Памяти компилятор требует больше, а не меньше. Предсказывалось плато; замер дал **N^0.68**. При фиксированном каталоге число уникальных *пар* user×item всё равно растёт с длиной лога. До 4 млн событий компилятор занимает **582 МиБ против 142** у жёстких окон: он держит 72 числа на ключ, а CSR окон — 8 байт на событие. Утверждение «O(1) на ключ против O(N) на события» верно асимптотически, но здесь перевешивает константа. Настоящее преимущество лежит на другой оси: **память не зависит от горизонта признака** — счётчик с полупериодом в год занимает столько же, сколько с полупериодом в час, а окну в год нужно держать события за год.

5. Синтетика насыщается и не различает методы. На управляемом полигоне все содержательные методы дают NDCG@10 в пределах 0.0014 друг от друга (0.9340–0.9354) при ширине интервала 0.011. Причина принципиальная: полигон порождён явной функцией нескольких затухающих счётчиков, и бустинг с этими счётчиками на входе её почти точно восстанавливает. *Вывод:* синтетика годится для валидации — восстановление масштабов, аудит утечки, отрицательные контроли, — но ранжировать методы по качеству можно только на реальных данных.

6. Полигон не удалось заставить проверить главное заявление — с трёх попыток. В генератор был намеренно добавлен сигнал в бренде (τ = 20 дней, вне ключей ручного набора) и оставлен шум в ценовом сегменте — как отрицательный контроль. Предсказывалось, что компилятор найдёт первое и отвергнет второе. Проверялось тремя способами: порядком добавления ключей, приростом метрики и прямой важностью признаков. **Ни один не подтвердил предсказание** (важность 1.1% против 0.9%, отношение 1.2×).

Причина измерена: ключ `user×item` забирает **80.7%** всей важности, и вторичные мета-пути остаются на уровне шума. Полигон, порождённый простой моделью с доминирующим механизмом, не способен разрешить второстепенные связи. Доказательство пользы перебора получено **на реальных данных**, где есть запас по метрике: подпространство человека даёт 0.3708, полный перебор — 0.4117, интервалы не пересекаются.

Что это даёт в сумме

Метод не «выигрывает везде». Он выигрывает там, где от него этого и ждут: **когда в схеме есть атрибуты, полезность которых заранее неизвестна.** На полигоне, где человек покрыл ровно заложенные механизмы, ручной набор оптимален по построению. На реальных данных, где заранее неясно, что

сработает — бренд, родительская категория, ценовой сегмент, — перебор находит то, чего человек не выписал, и это даёт значимый прирост.

Грамматика признаков

Два уровня. Крошечный набор примитивов порождает огромное пространство.

Уровень 0 — требует прохода по логу, всё O(1) на событие

статистика	смысл	состояние
`dcount`	затухающий счётчик событий	`A`
`dage_mean`	средний возраст истории	`B/A`
`dage_std`	разброс возрастов	`√(C/A − (B/A)²)`
`recency`	время с последнего события	`t − t_last`
`age`	время с первого события	`t − t_first`

Уровень 1 — чистая арифметика, НОЛЬ проходов по логу

операция	смысл	пример
`conversion`	конверсия между типами событий	purchase/view на `user×item`
`share`	доля активности	`user×item / user` = share of wallet
`trend`	контраст масштабов	короткий полупериод / длинный
`lift`	PMI-подобная поправка на популярность	`obs·glob / (marg_u·marg_i)`

`trend` и `lift` руками почти никогда не пишут: для первого нужно заранее держать два согласованных окна, для второго — четыре согласованных счётчика.

Отношения считаются в **логарифмической форме** `log1p(a) − log1p(b)`. Аддитивное сглаживание `a/(b+1)` корректно для сырых счётчиков, но затухающие имеют масштаб 0.1–5, и константа 1.0 полностью подавляет сигнал — это было видно в первом прогоне бенчмарка напрямую.

Из схемы на 5 столбцов и 3 типа событий перебор даёт **1 944 признака**, из которых проход по логу нужен только **1 040**.

Моменты возрастов: правильный примитив

Раз имитировать окно нельзя (результат 1), нужен другой примитив.

Чем вообще является окно? Это **один срез распределения возрастов** событий: «какая доля истории моложе W». Человек, выбирая набор окон, грубо сэмплирует функцию распределения возрастов в нескольких точках.

Вместо срезов берём **моменты** этого распределения, взвешенного затуханием. Пусть `s_j = t − t_j` — возраст j-го события:

$$A = \sum_j e^{-\lambda s_j}, \qquad B = \sum_j s_j e^{-\lambda s_j}, \qquad C = \sum_j s_j^2 e^{-\lambda s_j}$$

При сдвиге времени на `Δ` все три поддерживаются за **O(1)**:

$$A \to e^{-\lambda\Delta} A, \qquad B \to e^{-\lambda\Delta}(B + \Delta A), \qquad C \to e^{-\lambda\Delta}(C + 2\Delta B + \Delta^2 A)$$

а приход события даёт `A += 1` (его возраст равен нулю, поэтому `B` и `C` не меняются). Проверено численно против определения: расхождение **1e-16** (`tests/test_engine.py`).

```
237def age_moment_decay_step(
238    A: float, B: float, C: float, lmbd: float, dt: float
239) -> tuple[float, float, float]:
240    """Один шаг затухания моментов на интервал dt. Эталон для тестов движка."""
241    e = np.exp(-lmbd * dt)
242    return e * A, e * (B + dt * A), e * (C + 2.0 * dt * B + dt * dt * A)
```

Содержательно: `A` отвечает на «сколько», `B/A` — на «когда», и ни то, ни другое не требует от человека выбирать границу окна.

Протокол оценки

Здесь сосредоточено почти всё, где обычно ломается честность сравнения.

1. **Сплит только по времени.** Случайный сплит в RecSys даёт утечку.
2. **Разрыв предсказания — 1 день.** Признаки считаются на момент `t − 1 день`. Без него задача сводится к детекции намерения внутри сессии (результат 4): медианный разрыв между покупкой и предыдущим касанием того же айтема — 4 минуты.
3. **Негативы как у ретривера**, а не по популярности: история пользователя 40%, та же категория 30%, популярность 30% (результат 5).
4. **Негативы — из распределения, построенного только по train.** Иначе в val/test просачивается информация о том, какие айтемы станут популярны.
5. **Разные размеры набора кандидатов на обучении и на оценке** (24 и 50). Обучению много негативов не нужно, а при 24 кандидатах на оценке `Recall@10` считается по почти половине списка и насыщается.
6. **Набор кандидатов один и тот же для всех методов.** Иначе сравниваются ретриверы, а не модели.
7. **Тюнинг каждому методу с одинаковым бюджетом.** Задание требует обыграть «хорошо затюненный бустинг» — сравнивать затюненный компилятор с дефолтным ручным набором нельзя.
8. **Отбор модели по log-loss, а не по AUC** — по причине из результата 2.
9. **Доверительные интервалы бутстрэпом по группам**, а не по строкам: строки внутри группы зависимы. В таблицах есть колонка «значимо»: она ставит «да» только если интервалы не пересекаются.
10. **В каждой таблице есть строка-ориентир** `ярлык «видел айтем»` — тривиальный бинарный признак. Без него нельзя понять, много ли значит полученное число: на вырожденном протоколе он один даёт NDCG@10 ≈ 0.91.

Атрибуты разрешаются AS OF момента запроса

Отдельная, неочевидная форма утечки, на которой легко сесть. Свойства айтема в RetailRocket временные: категория и цена меняются. Джойн «айтем → последнее известное значение» подставляет событию из мая категорию, присвоенную в сентябре.

```
    q_rank = np.int8(2) if queries_after_events else np.int8(0)
    sec = np.concatenate([np.full(m, q_rank, np.int8), np.ones(n, np.int8)])
    qpos_all = np.concatenate([np.arange(m, dtype=np.int32),
                               np.full(n, -1, dtype=np.int32)])
    is_q_all = np.concatenate([np.ones(m, bool), np.zeros(n, bool)])
    etype_all = np.concatenate([np.full(m, -1, np.int8), log.etype])

    order = np.lexsort((sec, t_all))

    columns: dict[str, np.ndarray] = {}
    for name in log.column_names:
        log_col = log.column(name)
        if m == 0:
            merged = log_col
```

```
def test_leak_detector_actually_detects_leak():
    """Позитивный контроль: если утечку внести намеренно, тест выше обязан
    её поймать. Иначе он ничего не проверяет.

    Вносим утечку самым типичным способом: сдвигаем запрос на час ВПЕРЁД,
    то есть позволяем ему увидеть события, которых в его момент не было.
    """
    log = make_log(n=4000)
    cut = log.time_quantile(0.6)
    q_all = make_queries(log, m=400)
    q = q_all.select(q_all.t < cut)
    prims = [Primitive(("user",), 0, "dcount", 7 * DAY)]

    honest = compute(log.slice_until(cut), q, prims)
    q_leaky = QuerySet(t=q.t + 7 * 86400, user=q.user, item=q.item, y=q.y,
                       group=q.group, attrs=q.attrs)
    leaky = compute(log, q_leaky, prims)
    assert not np.allclose(np.nan_to_num(honest), np.nan_to_num(leaky)), \
        "детектор утечки не видит заведомую утечку"


def test_hand_baseline_is_also_leak_free():
```

Эта утечка **не ловится** обычной проверкой агрегатов, потому что сидит в джойне атрибутов, а не в них. Цена вопроса измерена: корректный as-of джойн знает категорию в **79.7%** событий, наивный — в **96.6%**. 17 пунктов чистой информации из будущего.

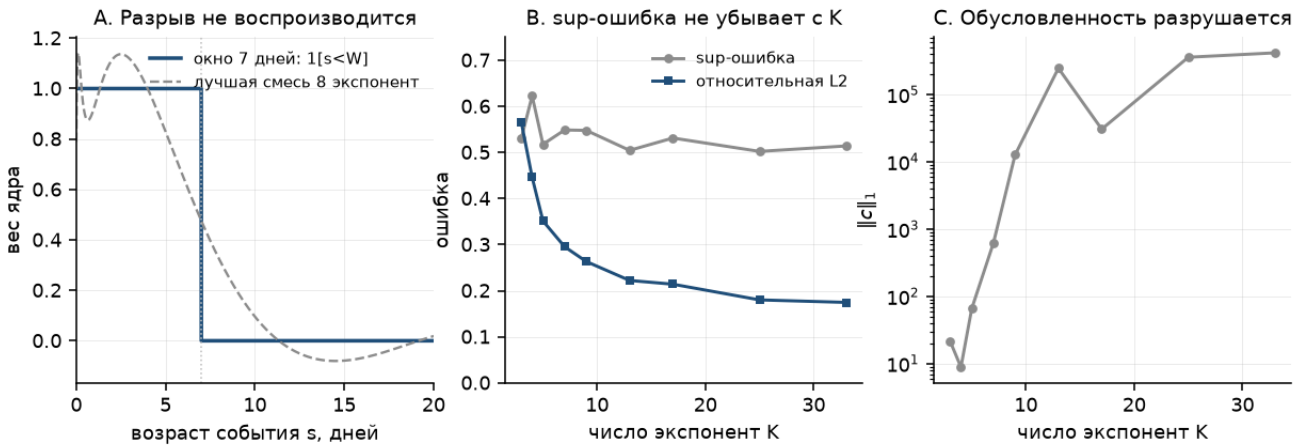
В первой версии `build_queries` эта ошибка была и у нас — нашлась при подготовке реальных данных, исправлена, покрыта тестом (`tests/test_asof.py`).

Baseline ручных фичей — не соломенное чучело

Реализован полный классический набор ровно в том виде, в каком его пишет ML-инженер: счётчики по типам событий в окнах **1/7/30/365 дней** на ключах `user`, `item`, `user×item`, `user×cat`, давность, возраст, уникальные партнёры, конверсии, доли. Окна считаются **точно**, бинарным поиском по CSR-раскладке.

Отдельным тестом подтверждено, что baseline **так же свободен от утечки**, как компилятор. Иначе сравнение нечестно в любую из сторон.

Эксперимент 1: окна против затуханий




```
e01.log — tbank-recsys-autofe

$ make e01

================================================================================
ЧАСТЬ B. ПРИБЛИЖЕНИЕ ПРИЗНАКА: главная проверка
================================================================================
  Ядро приближено плохо, но признак — это интеграл по ядру.
  Могла ли ошибка усредниться на реальных историях событий?

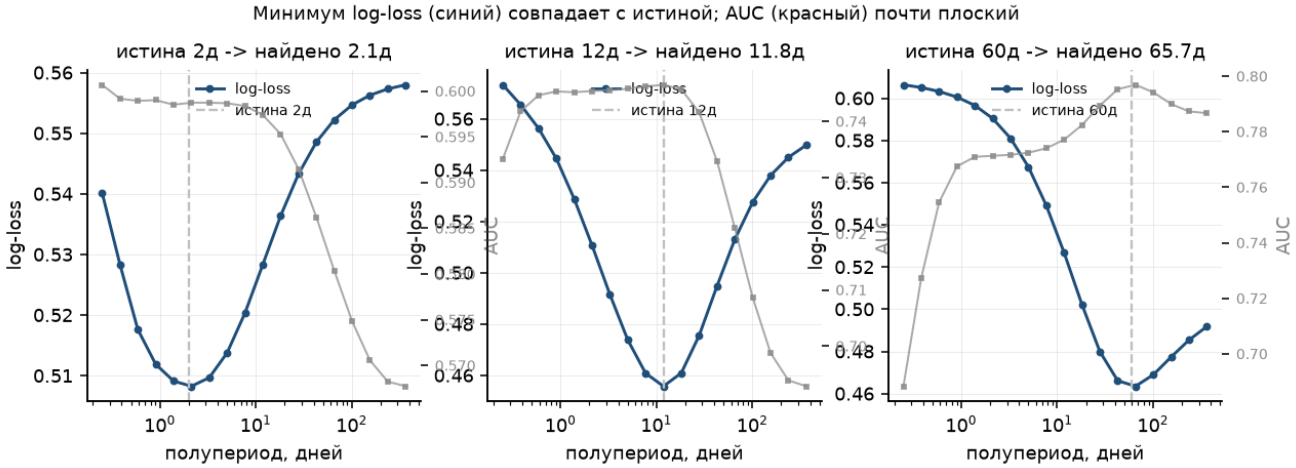
  событий/день      corr     отн.MAE             R^2   историй
          0.05   -0.0095      6391.0       -1.49e+07     4,000
          0.20    0.0142      6234.1       -5.39e+07     4,000
          1.00    0.0269      6178.7       -2.62e+08     4,000
          5.00   -0.0129      6191.4       -1.33e+09     4,000

  Не усредняется. При ||c||_1 = 1063 восстановление
  окна из базиса затуханий — плохо обусловленная обратная задача
  Лапласа, и шум усиливается катастрофически.

  ВЫВОД: окно и затухающий счётчик не выражаются друг через друга
  устойчиво. Сравнивать их можно только экспериментально, что и
  делается в экспериментах 2 и 3. А правильный примитив — не
  имитация окна, а моменты затухающего распределения возрастов.
================================================================================
результаты: reports/e01_window_vs_decay.json
```

Полный разбор — в «Главные результаты», пункт 1. Воспроизводится командой `make e01`.

Эксперимент 2: существует ли «правильное окно»




```
e02.log — tbank-recsys-autofe

$ make e02

    побочный сдвиг у «повтор айтема»: 3.6x
    побочный сдвиг у «трендовость айтема»: 5.6x

  свип tau_item_days:
      значение   интерес к категории        повтор айтема    трендовость айтема
            1д                18.17д                18.17д                 7.71д
            4д                18.17д                11.84д                11.84д
           40д                27.89д                27.89д                18.17д
    параметр менялся в 40x, оптимум сдвинулся в 2.4x, монотонно: НЕТ
    побочный сдвиг у «интерес к категории»: 1.5x
    побочный сдвиг у «трендовость айтема»: 2.4x

  свип tau_pop_days:
      значение   интерес к категории        повтор айтема    трендовость айтема
            2д                18.17д                11.84д                11.84д
           10д                18.17д                11.84д                11.84д
           60д                18.17д                11.84д                 3.27д
    параметр менялся в 30x, оптимум сдвинулся в 3.6x, монотонно: НЕТ
    побочный сдвиг у «интерес к категории»: 1.0x
    побочный сдвиг у «повтор айтема»: 1.0x

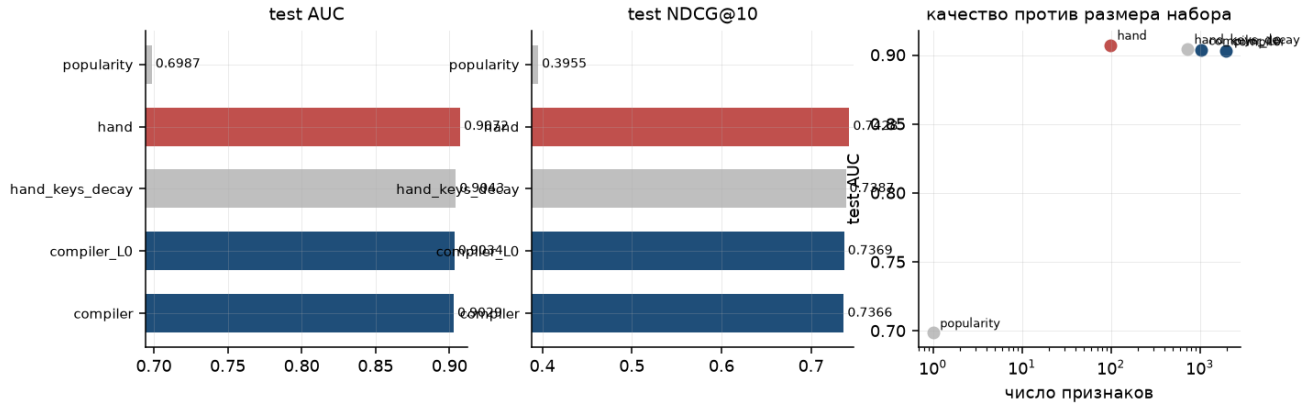
  Итог: оптимум не воспроизводит параметры механизмов — он насыщается,
  реагирует немонотонно и смещается от ЧУЖИХ параметров, потому что
  механизмы связаны между собой. Если правильный полупериод не выводится
  из полного знания устройства полигона, на реальных данных он не
  выводится тем более. Остаётся измерять: держать всю сетку масштабов
  и отдавать выбор модели.
================================================================================

результаты: reports/e02_timescales.json
```

Часть A — идентифицируемость. На хирургическом полигоне метка строится ровно из одного затухающего счётчика с известным полупериодом, то есть оптимум существует по построению. log-loss находит его в пределах разрешения сетки; AUC — нет.

Часть B — выводим ли оптимум из знания механизмов. Нет: оптимум насыщается, реагирует немонотонно и смещается от ЧУЖИХ параметров, потому что механизмы связаны. Детали и таблицы свипов — в «Главные результаты», пункт 3.

Эксперимент 3: сквозной бенчмарк



На реальных данных (RetailRocket)

```
e03_retailrocket.log — tbank-recsys-autofe

$ make e03-rr

БЕНЧМАРК: компилятор против затюненного ручного бустинга
датасет: retailrocket, событий: 782,330
протокол негативов: mixed  (имитация ретривера: история + категория + популярность)
разрыв предсказания: 1 дн.
================================================================================================================
метод                 призн.      AUC   logloss   NDCG@10  Recall@10     MRR   фичи,с  тюнинг,с  чел.-ч
----------------------------------------------------------------------------------------------------------------
seen                       1   0.5048   0.10519    0.0000     0.0000  0.0446      0.1         5     0.1  [0.00
00,0.0000]
popularity                 1   0.4468   0.10531    0.1255     0.2310  0.1210      0.0         8     0.2  [0.11
69,0.1349]
hand                      98   0.8062   0.08417    0.3733     0.6379  0.3124      7.2        65     6.0  [0.35
92,0.3850]
hand_keys_decay          720   0.7963   0.08515    0.3708     0.6369  0.3088      5.2       376     0.1  [0.35
48,0.3837]
compiler_L0            1,040   0.8097   0.08308    0.4035     0.6482  0.3469      5.7       651     0.0  [0.38
85,0.4171]
compiler               1,944   0.8149   0.08260    0.4117     0.6684  0.3507     13.9      1926     0.0  [0.39
92,0.4260]
compiler_selected      1,944   0.8149   0.08260    0.4117     0.6684  0.3507     13.7      2670     0.0  [0.39
92,0.4260]
----------------------------------------------------------------------------------------------------------------
прирост к hand:
  seen                    -0.3015  +0.02102   -0.3733    -0.6379 -0.2678
  popularity              -0.3594  +0.02114   -0.2478    -0.4069 -0.1914
  hand_keys_decay         -0.0099  +0.00097   -0.0025    -0.0010 -0.0036
  compiler_L0             +0.0035  -0.00109   +0.0302    +0.0103 +0.0345
  compiler                +0.0087  -0.00157   +0.0384    +0.0305 +0.0382
  compiler_selected        +0.0087  -0.00157   +0.0384    +0.0305 +0.0382
================================================================================================================
результаты: reports/e03_benchmark_retailrocket.json
```

Датасет: **retailrocket**, событий 782,330. Негативов: 23 на обучении, 49 на оценке. Протокол негативов: `mixed`. Бюджет тюнинга: 8 испытаний каждому методу. Разрыв предсказания: 1 дн.

метод	признаков	AUC	logloss	NDCG@10	95% ДИ для NDCG@10	Recall@10	фичи, с	чел.-ч
ярлык «видел айтем» (ориентир)	1	0.5048	0.10519	0.0000	[0.0000, 0.0000]	0.0000	0.1	0.1
популярность (ориентир)	1	0.4468	0.10531	0.1255	[0.1169, 0.1349]	0.2310	0.0	0.2
ручные фичи, жёсткие окна	98	0.8062	0.08417	0.3733	[0.3592, 0.3850]	0.6379	7.2	6.0
те же ключи, сетка масштабов	720	0.7963	0.08515	0.3708	[0.3548, 0.3837]	0.6369	5.2	0.1
компилятор, уровень 0	1,040	0.8097	0.08308	**0.4035**	[0.3885, 0.4171]	0.6482	5.7	0.0
компилятор, уровни 0+1	1,944	0.8149	0.08260	**0.4117**	[0.3992, 0.4260]	0.6684	13.9	0.0
компилятор + отбор на val	1,944	0.8149	0.08260	**0.4117**	[0.3992, 0.4260]	0.6684	13.7	0.0

Прирост к ручному набору. Колонка «значимо» отвечает на вопрос, различимы ли методы вообще: различие считается значимым, только если доверительные интервалы NDCG@10 не пересекаются.

метод	ΔAUC	ΔNDCG@10	ΔRecall@10	значимо
ярлык «видел айтем» (ориентир)	-0.3015	-0.3733	-0.6379	да
популярность (ориентир)	-0.3594	-0.2478	-0.4069	да
те же ключи, сетка масштабов	-0.0099	-0.0025	-0.0010	нет
компилятор, уровень 0	+0.0035	+0.0302	+0.0103	да
компилятор, уровни 0+1	+0.0087	+0.0384	+0.0305	да
компилятор + отбор на val	+0.0087	+0.0384	+0.0305	да

На управляемом синтетическом полигоне

Датасет: **synthetic**, событий 1,000,000. Негативов: 23 на обучении, 49 на оценке. Протокол негативов: `mixed`. Бюджет тюнинга: 8 испытаний каждому методу. Разрыв предсказания: 1 дн.

метод	признаков	AUC	logloss	NDCG@10	95% ДИ для NDCG@10	Recall@10	фичи, с	чел.-ч
ярлык «видел айтем» (ориентир)	1	0.8772	0.07601	0.3339	[0.3297, 0.3382]	0.8658	0.2	0.1
популярность (ориентир)	1	0.8292	0.08901	0.2993	[0.2898, 0.3061]	0.6092	0.0	0.2
ручные фичи, жёсткие окна	98	0.9971	0.01496	0.9354	[0.9301, 0.9406]	0.9820	24.3	6.0
те же ключи, сетка масштабов	720	0.9970	0.01474	0.9347	[0.9294, 0.9404]	0.9802	6.4	0.1
компилятор, уровень 0	1,040	0.9968	0.01488	0.9340	[0.9285, 0.9395]	0.9795	8.1	0.0
компилятор, уровни 0+1	1,944	0.9969	0.01472	0.9352	[0.9296, 0.9407]	0.9808	20.2	0.0
компилятор + отбор на val	800	0.9969	0.01470	0.9350	[0.9295, 0.9404]	0.9812	22.6	0.0

Прирост к ручному набору. Колонка «значимо» отвечает на вопрос, различимы ли методы вообще: различие считается значимым, только если доверительные интервалы NDCG@10 не пересекаются.

метод	ΔAUC	ΔNDCG@10	ΔRecall@10	значимо
ярлык «видел айтем» (ориентир)	-0.1199	-0.6015	-0.1162	да
популярность (ориентир)	-0.1679	-0.6361	-0.3728	да
те же ключи, сетка масштабов	-0.0002	-0.0007	-0.0018	нет
компилятор, уровень 0	-0.0003	-0.0014	-0.0025	нет
компилятор, уровни 0+1	-0.0002	-0.0002	-0.0012	нет
компилятор + отбор на val	-0.0002	-0.0004	-0.0008	нет

Эксперимент 4: идея про ИИ-агента

```
e04.log — tbank-recsys-autofe

$ make e04

  Поэтому угадывание внутри этого пространства не может выиграть у
  исчерпывающего перебора — только совпасть. Ценность агента и
  человека остаётся в перечисленных пунктах ВНЕ грамматики, и это
  конкретный список, а не общие слова.

================================================================================
ЧАСТЬ 2. УГАДЫВАНИЕ ПРОТИВ ПЕРЕБОРА С ОТБОРОМ, при одинаковом k
================================================================================
  полное пространство 1,944, правдоподобное подпространство 192

    k  метод                                  AUC    NDCG@10   Recall@10
--------------------------------------------------------------------------------
   50  компилятор (top-k из всех)          0.9703     0.8276      0.9357
       идеальный агент (top-k из подпр.)   0.9693     0.8243      0.9313
       агент угадывает (среднее)           0.9697     0.8267      0.9320
         +- по прогонам                    0.0002     0.0004      0.0008
--------------------------------------------------------------------------------
  150  компилятор (top-k из всех)          0.9695     0.8246      0.9313
       идеальный агент (top-k из подпр.)   0.9700     0.8270      0.9350
       агент угадывает (среднее)           0.9703     0.8284      0.9347
         +- по прогонам                    0.0003     0.0012      0.0012
--------------------------------------------------------------------------------
================================================================================
результаты: reports/e04_vs_agent.json
```

Вложенность. Из 27 признаков, которые предлагает языковая модель для этой постановки, **19 (70%) уже порождаются грамматикой** автоматически. Угадывание внутри перечисляемого пространства не может выиграть — только совпасть.

Что остаётся вне грамматики (и где агент с человеком полезны):

- совпадает ли категория айтема с категорией ПОСЛЕДНЕГО просмотра — *последовательность, порядок событий*
- item-item co-visitation: что покупают вместе с этим — *мета-путь длины 3: user->item->user->item*
- косинус между эмбеддингами юзера и айтема (ALS / word2vec) — *обучаемые представления*
- длина сессии, позиция в сессии, dwell time — *сессионная структура*
- час дня, день недели, праздник — *календарные признаки*
- абсолютная цена и цена относительно средней по категории — *агрегация ЧИСЛОВОГО значения, а не ключа*
- марковские переходы между категориями — *последовательность, порядок событий*
- признаки из текста и картинок товара — *контент*

Угадывание против перебора с отбором при одинаковом k (полное пространство 1,944, правдоподобное подпространство 192):

k	метод	AUC	NDCG@10
50	компилятор (top-k из всех)	0.9703	0.8276
	идеальный агент (top-k из подпространства)	0.9693	0.8243
	агент угадывает (среднее ± σ)	0.9697 ± 0.0002	0.8267 ± 0.0004
150	компилятор (top-k из всех)	0.9695	0.8246
	идеальный агент (top-k из подпространства)	0.9700	0.8270
	агент угадывает (среднее ± σ)	0.9703 ± 0.0003	0.8284 ± 0.0012

Эксперимент 5: аудит утечки

```
e05.log — tbank-recsys-autofe

$ make e05

================================================================================
ЧАСТЬ 2. ПОЗИТИВНЫЕ КОНТРОЛИ: насколько утечка завышает метрику
================================================================================
вариант                 AUC     dAUC   logloss   NDCG@10    dNDCG     MRR
--------------------------------------------------------------------------------
honest               0.9693  +0.0000   0.06066    0.8254  +0.0000  0.7949
no_gap               0.9696  +0.0003   0.06032    0.8259  +0.0005  0.7963
future_window        0.9997  +0.0304   0.00376    0.9964  +0.1710  0.9951
self_timestamp       0.9695  +0.0002   0.06037    0.8279  +0.0025  0.7991
--------------------------------------------------------------------------------
  honest            корректный протокол: разрыв 1 день, as-of атрибуты
  no_gap            забыт разрыв предсказания: признаки на момент покупки
  future_window     признаки считаются на 7 дней позже момента запроса
  self_timestamp    запрос видит событие в свой же момент (под разрывом не должен влиять)

  no_gap            dNDCG@10 = +0.0005  ->  не влияет (ожидаемо под разрывом)
  future_window     dNDCG@10 = +0.1710  ->  ЗАВЫШАЕТ метрику
  self_timestamp    dNDCG@10 = +0.0025  ->  не влияет (ожидаемо под разрывом)

  Про self_timestamp отдельно: под разрывом предсказания запрос стоит
  в момент t минус сутки, где событий этого пользователя нет, поэтому
  ошибка в строгости неравенства физически не может проявиться.
  Разрыв попутно защищает и от неё — это не недостаток контроля,
  а свойство протокола, и оно здесь измерено, а не предположено.
================================================================================
результаты: reports/e05_leak_audit.json
```

Часть 1 — проверка отсутствия утечки. Признаки считаются дважды: на полном логе и на логе, обрезанном по границе train.

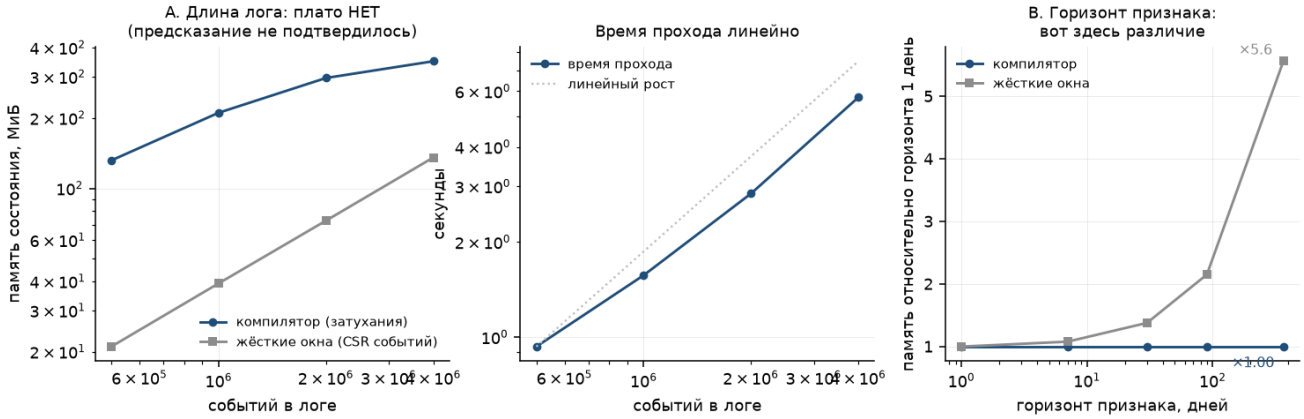
проверено признаков	строк-запросов	признаков с отличиями	макс. отн. отличие
1,944	193,944	0	0.0e+00

Вердикт: **утечки не обнаружено**.

Часть 2 — позитивные контроли. Без них часть 1 ничего не доказывает: тест, не способный поймать утечку, пройдёт и на сломанном коде.

вариант	AUC	ΔAUC	NDCG@10	ΔNDCG@10	что это
`honest`	0.9693	+0.0000	0.8254	+0.0000	корректный протокол: разрыв 1 день, as-of атрибуты
`no_gap`	0.9696	+0.0003	0.8259	+0.0005	забыт разрыв предсказания: признаки на момент покупки
`future_window`	0.9997	+0.0304	0.9964	+0.1710	признаки считаются на 7 дней позже момента запроса
`self_timestamp`	0.9695	+0.0002	0.8279	+0.0025	запрос видит событие в свой же момент (под разрывом не должен влиять)

Эксперимент 6: масштабирование




```
e06.log — tbank-recsys-autofe

$ make e06

============================================================================================================
лог 2,000,000 событий, каталог тот же

    горизонт        компилятор      жёсткие окна   отношение
        1 дн.           309 МиБ           12 МиБ        0.0x
        7 дн.           309 МиБ           13 МиБ        0.0x
       30 дн.           309 МиБ           17 МиБ        0.1x
       90 дн.           309 МиБ           27 МиБ        0.1x
      365 дн.           309 МиБ           68 МиБ        0.2x

  горизонт вырос в 365x:
    память компилятора изменилась в 1.00x
    память жёстких окон выросла в  5.56x

  Вот настоящее структурное различие: счётчик с полупериодом в год
  занимает столько же, сколько с полупериодом в час, а окну в год
  нужно держать события за год.

============================================================================================================
  при росте лога в 8x:
    состояние компилятора выросло в 2.66x
    состояние жёстких окон выросло в 6.44x
============================================================================================================
результаты: reports/e06_scaling.json
```

Часть A — длина лога. Каталог зафиксирован (50,000 юзеров, 10,000 айтемов), растёт только число событий. Предсказывалось плато у компилятора — **предсказание не подтвердилось**: при фиксированном каталоге число уникальных *пар* user×item всё равно растёт с длиной лога.

событий	проход, с	тыс. строк/с	состояние компилятора	состояние окон	отношение
500,000	0.9	557	132 МиБ	21 МиБ	0.2×
1,000,000	1.6	650	211 МиБ	39 МиБ	0.2×
2,000,000	2.8	710	296 МиБ	73 МиБ	0.2×
4,000,000	5.7	701	350 МиБ	135 МиБ	0.4×

Показатели степени в `y ~ N^a`: время прохода **N^0.84** (линейность = 1.00), состояние компилятора **N^0.47** (плато было бы 0.00), состояние жёстких окон **N^0.90**.

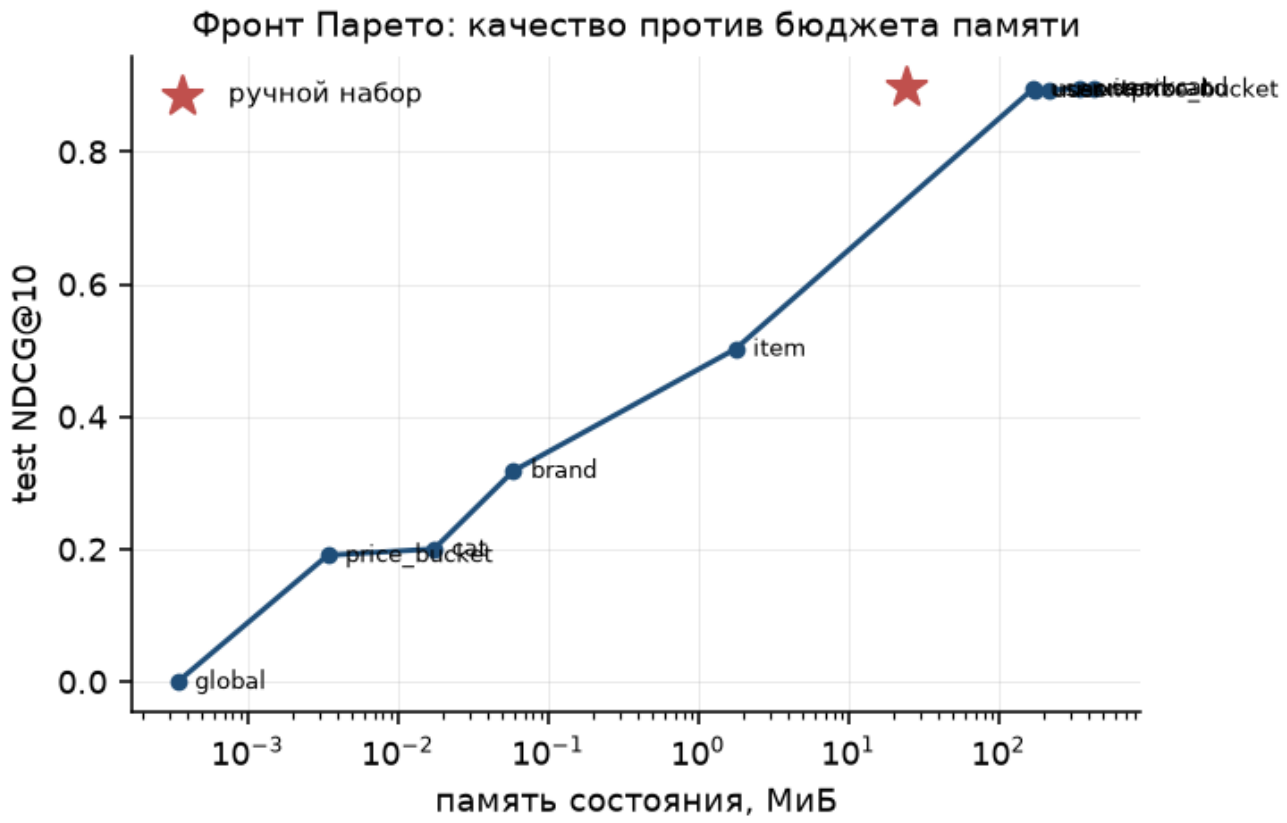
На этих масштабах компилятор занимает **больше** памяти, чем жёсткие окна: он держит 72 числа на ключ, а CSR окон — 8 байт на событие. Утверждение «O(1) на ключ против O(N) на события» верно асимптотически, но здесь перевешивает константа.

Часть B — горизонт признака. Вот ось, на которой разница принципиальна. Лог зафиксирован, растёт только самый длинный временной масштаб.

горизонт	компилятор	жёсткие окна
1 дн.	309 МиБ	12 МиБ
7 дн.	309 МиБ	13 МиБ
30 дн.	309 МиБ	17 МиБ
90 дн.	309 МиБ	27 МиБ
365 дн.	309 МиБ	68 МиБ

Горизонт вырос в 365×: память компилятора изменилась в **1.00×**, память жёстких окон — в **5.56×**. Счётчик с полупериодом в год занимает ровно столько же, сколько с полупериодом в час, а окну в год нужно держать события за год.

Эксперимент 7: отбор под бюджет



e07.log — tbank-recsys-autofe

```
$ make e07

  userxprice_bucket        0.9%

  ПРОВЕРКА ПОЛИГОНА: в бренде сигнал (tau=20д), в цене шум.
    userxbrand         1.1%
    userxprice_bucket 0.9%
    отношение 1.2x  ->  РАЗЛИЧИЯ НЕТ

=================================================================================================
добавлен ключ                 память  обновл/соб  признаков      AUC   NDCG@10
-------------------------------------------------------------------------------------------------
global                         0.0 МиБ          24        156   0.5000    0.0000
price_bucket                   0.0 МиБ          48        312   0.5220    0.1912
cat                            0.0 МиБ          72        468   0.5491    0.2008
brand                          0.1 МиБ          96        624   0.6555    0.3185
item                           1.8 МиБ         120        780   0.8330    0.5026
userxitem                    168.6 МиБ         144        968   0.9626    0.8948
user                         175.5 МиБ         168       1188   0.9871    0.8932
userxprice_bucket            218.9 МиБ         192       1440   0.9875    0.8937
userxbrand                   349.6 МиБ         216       1692   0.9874    0.8955
userxcat                     435.6 МиБ         240       1944   0.9882    0.8969
-------------------------------------------------------------------------------------------------
ручной набор (окна)           24.1 МиБ                    98   0.9884    0.8983
-------------------------------------------------------------------------------------------------
  компилятор не достигает NDCG@10=0.8983 ни на одном бюджете
=================================================================================================
результаты: reports/e07_budget.json
```

Какие мета-пути метод реально использует (суммарный gain, без поправки на стоимость):

ключ	доля важности
`userxitem`	80.7%
`item`	4.4%
`brand`	3.4%
`price_bucket`	2.9%
`cat`	2.6%
`global`	1.7%
`user`	1.2%
`userxbrand`	1.1%
`userxcat`	1.0%
`userxprice_bucket`	0.9%

Ключ `userxitem` забирает **80.7%** всей важности. Остальные девять делят остаток, и всё ниже `item` лежит на уровне шума.

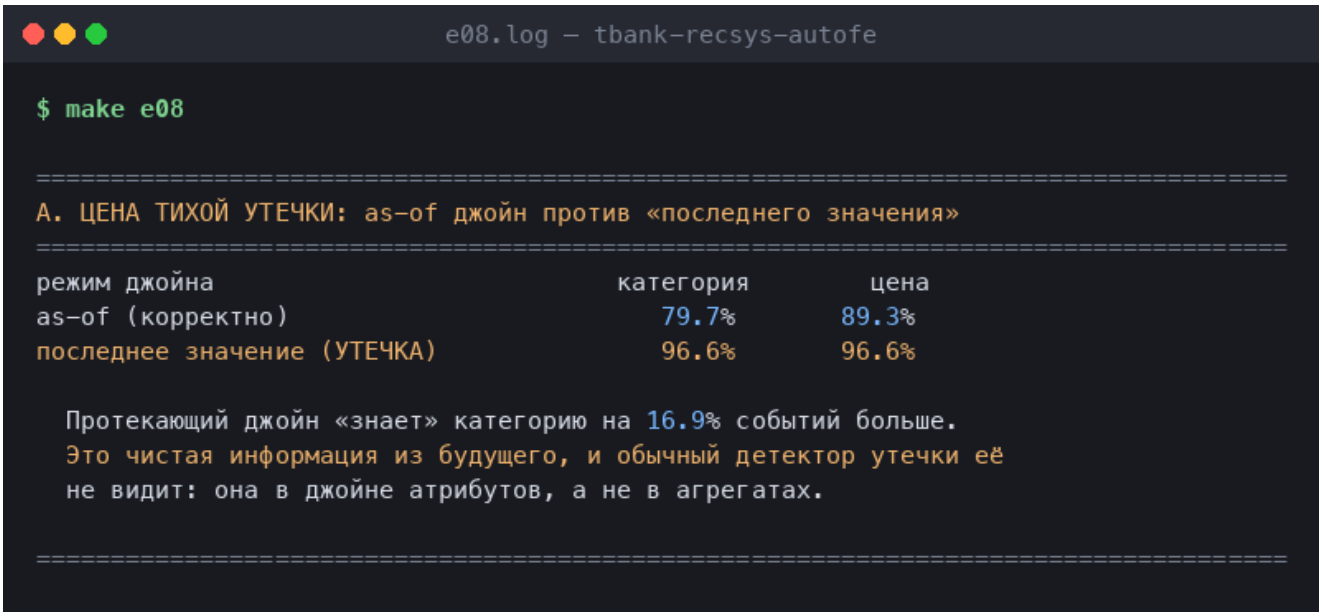
Проверка полигона, которая не прошла. В генераторе бренд несёт сигнал (τ = 20 дней), а ценовой сегмент — чистый шум. Предсказывалось, что важность `userxbrand` заметно превысит `userxprice_bucket`. Замер: **1.1% против 0.9%**, отношение 1.2× — **различия нет**.

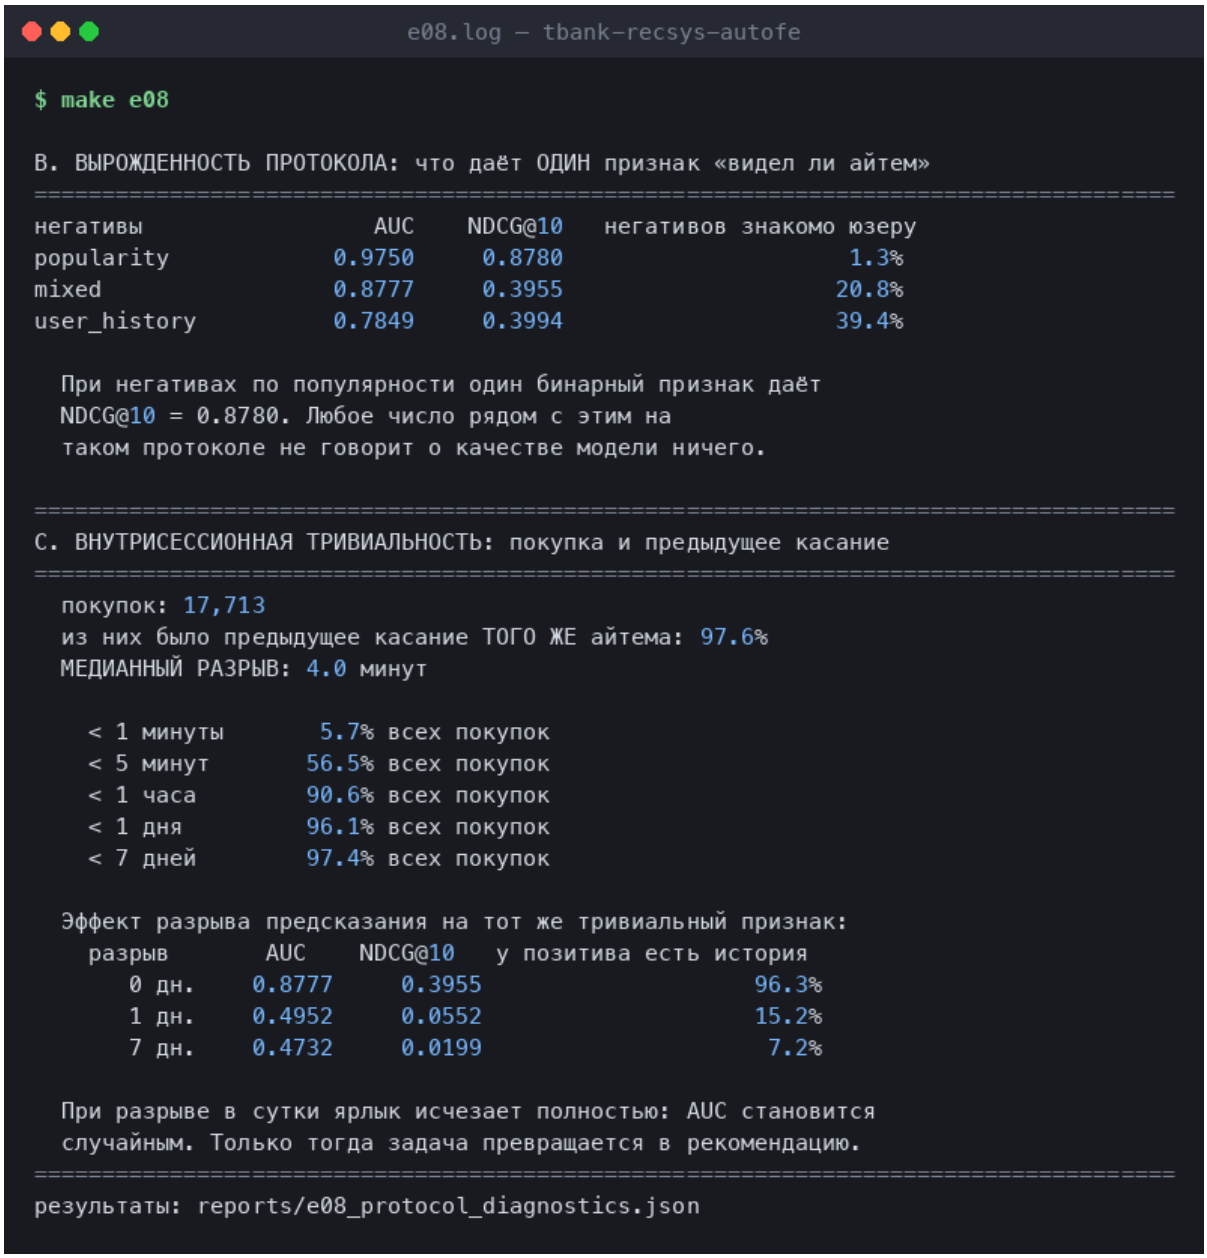
Причина видна в той же таблице: доминирование `userxitem` оставляет вторичным мета-путям уровень шума, и на этом полигоне они неразличимы в принципе. Это ограничение синтетики, а не результат метода; доказательство пользы перебора получено на реальных данных, где есть запас по метрике.

добавлен ключ	память состояния	обновлений/событие	признаков	AUC	NDCG@10
`global`	0.0 МиБ	24	156	0.5000	0.0000
`price_bucket`	0.0 МиБ	48	312	0.5220	0.1912
`cat`	0.0 МиБ	72	468	0.5491	0.2008
`brand`	0.1 МиБ	96	624	0.6555	0.3185
`item`	1.8 МиБ	120	780	0.8330	0.5026
`userxitem`	168.6 МиБ	144	968	0.9626	0.8948
`user`	175.5 МиБ	168	1188	0.9871	0.8932
`userxprice_bucket`	218.9 МиБ	192	1440	0.9875	0.8937
`userxbrand`	349.6 МиБ	216	1692	0.9874	0.8955
`userxcat`	435.6 МиБ	240	1944	0.9882	0.8969
ручной набор (окна)	24.1 МиБ	—	98	0.9884	0.8983

Эксперимент 8: диагностика протокола

Три замера, которые заставили переделать протокол оценки. Без них остальные числа читать нельзя.





A. Цена тихой утечки в джойне атрибутов.

режим джойна	известна категория	известна цена
as-of (корректно)	79.7%	89.3%
последнее значение (УТЕЧКА)	96.6%	96.6%

Протекающий джойн «знает» категорию на **16.9%** событий больше — это чистая информация из будущего, и обычный детектор утечки её не видит.

B. Вырожденность протокола негативов. Что даёт ОДИН бинарный признак «взаимодействовал ли юзер с этим айтемом раньше»:

негативы	AUC	NDCG@10	негативов знакомо пользователю
`popularity`	0.9750	0.8780	1.3%
`mixed`	0.8777	0.3955	20.8%
`user_history`	0.7849	0.3994	39.4%

При негативах по популярности тривиальный признак даёт NDCG@10 = **0.8780**. Любое число рядом с этим на таком протоколе не говорит о качестве модели ничего.

C. Внутрисессионная тривиальность цели. Из 17,713 покупок у **97.6%** было предыдущее касание ТОГО ЖЕ айтема. Медианный разрыв — **4.0 минут**.

разрыв между покупкой и предыдущим касанием	доля всех покупок
< 1 минуты	5.7%
< 5 минут	56.5%
< 1 часа	90.6%
< 1 дня	96.1%
< 7 дней	97.4%

Эффект разрыва предсказания на тот же признак:

разрыв	AUC	NDCG@10	у позитива есть история по айтему
0 дн.	0.8777	0.3955	96.3%
1 дн.	0.4952	0.0552	15.2%
7 дн.	0.4732	0.0199	7.2%

При разрыве в сутки ярлык исчезает полностью: AUC становится случайным. Только тогда задача превращается в рекомендацию.

Чего метод НЕ делает

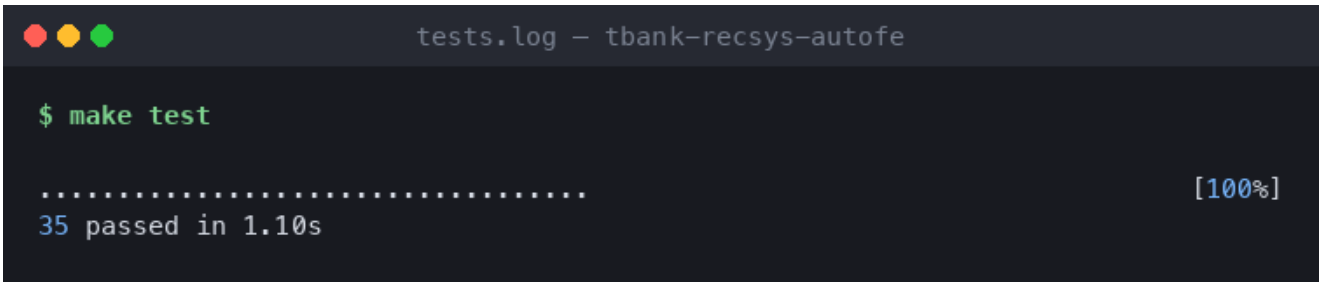
Честный список того, что в грамматику не входит. Это и есть место, где человек и агент остаются полезны.

не покрывается	почему
«та же категория, что у ПОСЛЕДНЕГО просмотра»	последовательность, порядок событий
item-item co-visitation («покупают вместе»)	мета-путь длины 3: user→item→user→item
косинус эмбеддингов (ALS, word2vec)	обучаемые представления
длина сессии, позиция в сессии, dwell time	сессионная структура
час дня, день недели, праздники	календарные признаки
абсолютная цена, цена относительно категории	агрегация числового значения, а не ключа
марковские переходы между категориями	последовательность
признаки из текста и картинок	контент

Первые два — естественные расширения (2-хоповые мета-пути через count-min sketch с затуханием), остальные требуют других примитивов.

Воспроизведение

```
make setup     # окружение (python 3.12, numba, lightgbm; на macOS нужен brew install libomp)
make test      # тесты корректности, включая аудит утечки
make data      # RetailRocket (нужен токен Kaggle)
make all       # все эксперименты и графики
```



Точные версии зафиксированы в `requirements.lock.txt`.

Структура

```
src/afe/
  log.py        склейка лога и запросов в один временной поток
  kernels.py    базис затуханий, моменты возрастов
  dsl.py        типизированная грамматика признаков
  schema.py     исчерпывающий перебор по схеме данных
  engine.py     однопроходный JIT-движок
  hand.py       baseline ручных фичей с точными окнами
  eval.py       протокол: сплит, кандидаты, метрики, бутстрэп
  select.py     отбор под бюджет (групповой рюкзак по ключам)
  model.py      бустинг, тюнинг с равным бюджетом
  datasets/     синтетические полигоны и RetailRocket
experiments/    e01..e07
tests/          23 теста
```